
Como escolher a técnica certa para cada problema?

Mineração de Dados, Ciência de Dados e Pandas

DISCIPLINA

Tópicos Especiais em Sistemas de Informação

CONTEXTO

Preparação ENADE 2026

PROFESSOR

Diogo Rodrigues

ENCONTROS

08/09/2026 (noite) · 11/09/2026 (manhã)

Problemas diferentes exigem abordagens diferentes

01 Mensagem é spam? — Identificar se uma mensagem é spam.

02 Quais perfis existem? — Formar grupos de usuários com comportamentos semelhantes.

03 O que ocorre junto? — Descobrir quais serviços são utilizados em conjunto.

Os três problemas poderiam ser resolvidos com a mesma técnica?

Em qual deles já conhecemos a resposta que desejamos prever?

Em qual deles os grupos ainda não foram definidos?

PERCURSO

1 Compreender o papel da Ciência de Dados

2 Reconhecer a etapa de compreensão do negócio

3 Diferenciar supervisionada e não supervisionada

4 Identificar classificação e clustering

5 Conhecer regras de associação

6 Interpretar GroupBy no Pandas

7 Resolver questões no estilo ENADE

Escolher o **algoritmo** antes de compreender o problema é começar pelo lugar **errado**

1 Qual é o problema?

2 Quem utilizará o resultado?

3 Qual decisão será apoiada?

4 Como o resultado será medido?

5 Quais dados estão disponíveis?

6 Existem restrições éticas ou institucionais?

Mineração de Dados é uma parte do processo de Ciência de Dados

CIÊNCIA DE DADOS · PROCESSO COMPLETO

1 Compreensão do negócio

2 Coleta dos dados

3 Preparação dos dados

4 Análise exploratória

5 Mineração e modelagem

6 Avaliação

7 Comunicação dos resultados

8 Implantação e acompanhamento — Mineração de Dados

O **modelo** é apenas uma etapa do trabalho

01 Problema de negócio

02 Dados

03 Preparação

04 **Modelagem**

05 Avaliação

06 Utilização

07 Monitoramento

Na aprendizagem supervisionada, o modelo aprende com **exemplos rotulados**

temp	vibricao	horas	alvo
78	alta	1200	falha
52	baixa	300	sem falha
81	alta	1450	falha
49	baixa	260	sem falha

Histórico rotulado: a coluna alvo já traz a resposta correta.

- 1 Existem exemplos anteriores.
- 2 A resposta correta é conhecida nos dados históricos.
- 3 O modelo aprende uma relação entre atributos e variável-alvo.
- 4 Depois, o modelo estima a resposta para novos registros.

Classificação prevê uma categoria previamente definida

Mensagem	Equipamento	Cliente
Spam	Com risco	Satisfeito
Não spam	Sem risco	Insatisfeito
Transação	Documento	A classificação pressupõe uma variável-alvo categórica: as classes existem antes do treinamento e cada exemplo histórico já está rotulado.
Legítima	Aprovado	
Suspeita	Reprovado	

Na aprendizagem **não supervisionada**, os grupos ainda não são conhecidos

- 1 Não existem rótulos prévios.
- 2 O algoritmo procura semelhanças ou estruturas.
- 3 Os resultados precisam ser interpretados.
- 4 Os grupos encontrados não possuem significado automático.

Clustering forma grupos com base na semelhança entre registros

Uma biblioteca deseja identificar perfis de utilização considerando:

Frequência de empréstimos

Tipos de livros

Tempo de permanência

Uso de materiais digitais

Participação em atividades

As categorias não foram definidas previamente. Os perfis **surgem da semelhança entre os registros e depois recebem um nome.**

A presença de rótulos diferencia classificação de clustering

CLASSIFICAÇÃO

Supervisionada

Possui variável-alvo

Utiliza exemplos rotulados

Prevê uma classe conhecida

CLUSTERING

Não supervisionado

Não possui variável-alvo

Procura semelhanças

Descobre grupos ainda não definidos

Por que **alta confiança** não garante relevância?

Suporte

RELEVÂNCIA GLOBAL

Mede a frequência da combinação dos itens no total de transações. Filtra associações raras que decorrem de ruído amostral.

Confiança

FORÇA APARENTE

Indica a proporção em que o consequente ocorre quando o antecedente está presente. *Pode iludir quando o consequente já é ultra-popular por conta própria.*

Lift

GANHO REAL

Compara a confiança da regra com a probabilidade esperada do consequente isolado. Mede se a relação supera o acaso.

ESCALA DE LEITURA DO LIFT

Lift > 1

Associação Positiva: O antecedente alavanca a ocorrência do consequente. Relação forte e útil.

Lift = 1

Independência: Os itens ocorrem juntos por pura coincidência estatística.

Lift < 1

Associação Negativa: Presença de um item inibe ou substitui a ocorrência do outro.



Regra de Ouro: Sempre avalie as três métricas juntas. O *suporte* valida o volume, a *confiança* indica a taxa de acerto condicional, e o *lift* confirma se há valor prático acima do acaso.

Caso Prático: A armadilha do "Pão → Café"

90%

Confiança Aparente (Pão → Café)

Parece uma excelente regra comercial à primeira vista, mas os dados completos revelam a verdade...

Confiança = $P(\text{Café} \mid \text{Pão}) = 0.90$

O Cenário Real do Supermercado:

Suponha que **90% de todos os clientes** comprem café, independentemente de comprarem pão ou não.

Logo, a probabilidade basal do consequente é $P(\text{Café}) = 0.90$.

Calculando o Lift:

$\text{Lift} = \text{Confiança} / P(\text{Café}) = 0.90 / 0.90 = 1.0$

Conclusão: O pão não tem nenhuma influência na venda do café! A alta confiança era apenas reflexo da enorme popularidade do café.

Um DataFrame organiza dados em linhas e colunas

unidade	tipo	tempo	avaliacao
Centro	Consulta	30	4
Norte	Exame	50	3
Centro	Exame	40	5
Norte	Consulta	25	4

Cada linha é um atendimento registrado; cada coluna é um atributo.

atendimentos

1 Linhas representam registros.

2 Colunas representam atributos.

3 Cada coluna pode ser selecionada, filtrada, agrupada ou resumida.

GroupBy reúne registros antes de aplicar uma agregação

```
atendimentos.groupby(  
    ["unidade", "tipo"],  
    as_index=False  
)["tempo"].mean()
```

unidade	tipo	tempo
Centro	Consulta	30
Centro	Exame	40
Norte	Consulta	25
Norte	Exame	50

Resultado: tempo médio por unidade e tipo, em formato tabular.

1 groupby — define os grupos.

2 ["unidade", "tipo"] — define as categorias.

3 ["tempo"] — seleciona a coluna numérica.

4 mean() — calcula a média.

5 as_index=False — mantém o resultado em formato tabular.

Agrupar define categorias; agregar produz o resumo

PIPELINE DE EXECUÇÃO

01

Dados Detalhados

16 atendimentos brutos registrados na base individual.

02

Agrupamento (Group)

Segmentação dos dados por **unidade** e **tipo**.

03

Agregação (Aggregate)

Cálculo de medidas de síntese (ex: cálculo da média).

04

Tabela Resumida

4 linhas consolidadas com o resumo final por categoria.

FUNÇÕES DE AGREGAÇÃO NO PANDAS

`mean()`

Média

`sum()`

Soma

`count()`

Contagem

`min()`

Mínimo

`max()`

Máximo

`std()`

Desvio Padrão

Exemplo direto com groupby e mean:

```
df.groupby(['unidade', 'tipo'])['tempo'].mean()
```

O Paradigma Split – Apply – Combine



1. Split (Dividir)

O DataFrame original é fatiado em subgrupos com base nos valores das colunas escolhidas.

```
df.groupby('categoria')
```



2. Apply (Aplicar)

Uma função matemática de agregação é calculada independentemente sobre cada subgrupo.

```
.agg('mean') ou .sum()
```



3. Combine (Juntar)

Os resultados isolados são recombinaados em um novo DataFrame sintetizado e pronto para análise.

```
Resultado: 4 linhas
```

Na prática: Redução dimensional com GroupBy

01. Dados Detalhados (Amostra de 16 registros)

ID	Unidade	Tipo	Tempo (min)
#01	F Recife	Exame	25
#02	F Recife	Consulta	15
#03	C Olinda	Exame	40
#04	C Olinda	Consulta	20
...	...	...	...

Total: 16 linhas de atendimentos individuais.

04. Resumo com .mean()

Unidade	Tipo	Média (min)
Recife	Consulta	16.5
Recife	Exame	28.0
Olinda	Consulta	21.0
Olinda	Exame	37.5

```
df.groupby(['unidade', 'tipo'])['tempo'].mean().reset_index()
```

Preencher com zero pode alterar o significado dos dados

🔍 INVESTIGAR ANTES DE TRATAR

- 01** Quantos valores estão ausentes no total?
- 02** Em quais grupos ou segmentos eles aparecem?
- 03** Por que esses valores estão ausentes?
- 04** Zero é um valor real válido nessa variável?
- 05** A ausência está correlacionada ao fenômeno?
- 06** A estratégia escolhida distorce as conclusões?

🏠 POSSIBILIDADES DE TRATAMENTO & PANDAS

Correção na Origem

Corrigir o registro direto no banco, API ou sistema transacional gerador.

`ETL / Source`

Exclusão Justificada

Remover linhas ou colunas segundo critério formal e documentado.

`df.dropna()`

Imputação Estatística

Estimar o valor a partir da distribuição dos dados (média, mediana, moda).

`.fillna(median)`

Indicador de Ausência

Criar uma coluna binária (flag) sinalizando que o dado original faltava.

`df.isna().astype(int)`

Métodos Compatíveis

Empregar algoritmos que toleram e tratam NaN nativamente.

`XGBoost / LightGBM`

O Perigo do .fillna(0): Distorção Estatística

⚠ Exemplo: Variável Salário ou Idade

Suponha 10 pessoas onde 2 não informaram o salário. Valores reais conhecidos: R\$ 5.000 a R\$ 6.000.

Operação executada: `df['salario'].fillna(0)`

Média Real (sem NaNs): **R\$ 5.400**

Média com Zero Imputado: **R\$ 4.320 (-20% de viés)**

Impacto nos modelos: **Cria bimodalidade artificial**

Consequência: Zero não é ausência de resposta, é o número zero. O modelo aprenderá que 2 pessoas têm renda nula.

✅ Quando Zero é Válido vs. Alternativas

Zero só faz sentido quando representa **ausência do evento quantificado** (ex.: "número de sinistros", "valor de multas").

Se a variável for métrica contínua: **Mediana com Flag**

Sintaxe recomendada: `df['salario'].fillna(media)`

Flag de auditoria: `df['salario_faltante'] = 1`

Média resultante: **R\$ 5.400 (Preservada)**

Vantagem: Preserva a tendência central e permite ao algoritmo saber quem tinha o dado omitido.

Avaliar nos mesmos dados de treino produz ilusão estatística

🕒 Partição Estratégica dos Dados



⚠️ Vazamento de Dados (Data Leakage)

Informações que **não estariam disponíveis** no momento real da previsão não podem ser utilizadas para treinar o modelo.

Exemplo Crítico: Normalizar ou imputar dados usando toda a base antes do split contamina o teste com informações do futuro.

💡 Por que a visão é enganosa?

Avaliar no treino testa apenas a **memória** do algoritmo (decorar os dados), e não a sua capacidade de **generalização** para prever o desconhecido.

A Ilusão do Treino: Acurácia Falsa de 99%

❌ Avaliar nos Dados de Treino

O algoritmo tem acesso a perguntas e gabaritos simultaneamente durante o treinamento.

Acurácia no Treino: **99.4% (Excelente!)**

Acurácia em Produção: **58.2% (Desastre real)**

Diagnóstico estatístico: **Overfitting Severo**

Efeito Aluno que Decora: O modelo memorizou o ruído da amostra, em vez de aprender as leis fundamentais do problema.

✅ Avaliar no Conjunto de Teste

O modelo é submetido a uma prova com dados rigorosamente isolados e guardados em cofre.

Acurácia no Treino: **84.0%**

Acurácia no Teste: **82.5% (Confiável)**

Expectativa em Produção: **~82% (Estável)**

Generalização Validada: O erro de teste é o único estimador não-viesado da performance em produção.

Vinte e um termos que sustentam a leitura de qualquer questão da área

PROCESSO

Ciência de Dados

Mineração de Dados

Compreensão do negócio

Vazamento de dados

ESTRUTURA DOS DADOS

Variável-alvo

Atributo preditor

Rótulo

Valor ausente

Imputação

APRENDIZAGEM

Aprendizagem supervisionada

Aprendizagem não supervisionada

Classificação

ASSOCIAÇÃO E PANDAS

Regra de associação

Suporte

Confiança

Lift

DataFrame

GroupBy

Agregação

Classificação supervisionada

Uma operadora de telecomunicações possui dados históricos de clientes que cancelaram e que não cancelaram seus contratos. A organização pretende construir um modelo capaz de prever quais clientes apresentam maior risco de cancelamento.

Qual técnica é mais adequada?

A. Agrupamento não supervisionado.

B. Classificação supervisionada.

C. Regras de associação sem variável-alvo.

D. Redução de dimensionalidade como resultado final.

E. Ordenação alfabética dos clientes.

Clustering

Uma empresa deseja separar seus clientes em grupos com comportamentos semelhantes. Entretanto, não existem categorias previamente definidas nem exemplos de classificação.

Qual técnica deve ser utilizada?

A. Regressão supervisionada.

B. Classificação binária.

C. Agrupamento ou clustering.

D. Teste de unidade.

E. Processamento de transações.

Compreensão do negócio

Uma equipe recebeu a solicitação de desenvolver um modelo para prever a evasão de estudantes. Antes de selecionar algoritmos, os profissionais entrevistaram os gestores acadêmicos para compreender o problema, definir evasão e identificar como o resultado seria utilizado.

Essa atividade pertence principalmente à etapa de:

A. compreensão do negócio.

B. implantação do modelo.

C. ajuste de hiperparâmetros.

D. substituição dos dados ausentes.

E. avaliação final do modelo em produção.

GroupBy no Pandas

Um DataFrame chamado vendas possui as colunas:

loja

categoria

valor

Qual comando Pandas calcula o valor total vendido por loja e categoria?

A. `vendas.sort_values(["loja", "categoria"])`

B. `vendas.merge(["loja", "categoria"])`

C. `vendas.groupby(["loja", "categoria"], as_index=False)["valor"].sum()`

D. `vendas.drop_duplicates(["loja", "categoria"])`

E. `vendas.loc[vendas["valor"].sum()]`